

# **Notas de Aula Análise de Sobrevivência**

Alisson Rosa

# Índice

<b>Prefácio</b>	<b>3</b>
<b>1 Introdução</b>	<b>4</b>
1.1 Breve História . . . . .	4
1.2 Porque estudar análise de sobrevivência? . . . . .	4
1.3 Censura . . . . .	5
1.3.1 Tipos de censura . . . . .	5
<b>2 Definições básicas</b>	<b>6</b>
2.1 Função de Sobrevivência . . . . .	6
2.2 Função taxa de falha . . . . .	6
2.2.1 Consequências . . . . .	8
<b>3 Programando</b>	<b>9</b>
3.1 Layout Básico . . . . .	9
<b>4 Análise Descritiva</b>	<b>11</b>
4.1 Estimando a função de sobrevivência . . . . .	11
4.1.1 Sem dados de censura . . . . .	11
<b>5 Estimador de Kaplan-Meier</b>	<b>13</b>
5.1 Outra maneira de layout para os dados . . . . .	13
5.2 Formalizando . . . . .	13
5.3 Propriedades do estimador . . . . .	15
5.3.1 Variância do Estimador . . . . .	15
5.4 Códigos . . . . .	15
<b>6 Summary</b>	<b>17</b>
<b>Referências</b>	<b>18</b>

# Prefácio

Notas de Aula do curso de análise de sobrevivência, as duas referências principais vão ser

- [Colosimo \(2006\)](#)

Em termos práticos, os códigos vão ser desenvolvidos usando as linguagens [Python](#) e [R](#), portanto assume-se conhecimentos básicos de ao menos umas dessas linguagens para um bom aproveitamento.

Encontrou algum erro? Pode encaminhar uma [issue](#) no repositório ou se preferir pode fazer um [pull request](#), **qualquer** contribuição construtiva é bem vinda.

# 1 Introdução

Análise de sobrevivência é a área que estuda o **tempo** até acontecer um evento de interesse acontecer. Como por exemplo:

- Tempo até os modelos convergirem
- Tempo até o equipamento falhar duas vezes
- Tempo até o customer não frequentar mais o local
- Tempo até um indivíduo casar-se por ano
- Tempo para o desenvolvimento da Covid-19

Note portanto, que o evento pode encapsular mais de um fato como **falhar duas vezes**

## 1.1 Breve História

Originalmente, análise de sobrevivência era usada exclusivamente para estudos de mortalidade em registros estatísticos. Sabe-se que as primeiras análises estatísticas de processos de sobrevivência foram desenvolvidas pelo estatístico [John Graunt](#), por um longo a análise de sobrevivência foi considerada um instrumento analítico para estudos de biomedicina e estudos demográficos, mas assim como estatística em geral alterou-se fortemente nas últimas décadas junto (causa?) com avanços computacionais, a análise de sobrevivência não foi diferente, pois atualmente possuímos um grande poder computacional para desenvolvimento de métodos estatísticos antes inviáveis

## 1.2 Porque estudar análise de sobrevivência?

Ok, porque não usar modelos de regressão em geral para modelar o Tempo ( $T$ )?. Um ponto fundamental aqui, é que nem sempre o evento de interesse acontece, assim gerando o que é conhecido como censura

## 1.3 Censura

Quando estamos fazendo uma análise de sobrevivência podemos ter indivíduos que por algum motivo tiveram que sair do estudo e não apresentaram o evento de interesse, portanto os dados desses indivíduos são chamados de **censurados**

### 1.3.1 Tipos de censura

## 2 Definições básicas

Seja  $f(t)$  a função densidade de probabilidade da variável aleatória  $T$  (tempo até o evento ocorrer). Definimos a função de distribuição acumulada da variável aleatória  $T$  como sendo:

$$F(t) = P(T < t) = \int_0^t f(u)du$$

### 2.1 Função de Sobrevivência

A função de sobrevivência é o complemento da função de distribuição acumulada, isso é: A probabilidade de uma observação não falhar até um tempo  $t$ :

$$S(t) = P(T > t) = 1 - F(t)$$

Pela Figura 2.1 podemos ter um vislumbre que  $S(0) = 1$  e  $S(\infty) = 0$ .

A demonstração de tais fatos fica a cargo do leitor, basta notar que  $S(t) = 1 - F(t)$  e usar as propriedades da  $F$ .

Por consequência a probabilidade de não sobreviver até um certo tempo  $t$  é:

$$1 - S(t)$$

Assim a probabilidade de não sobreviver em um intervalo  $(t_1, t_2)$  é dado por:

$$1 - S(t_2) - (1 - S(t_1)) = S(t_1) - S(t_2)$$

### 2.2 Função taxa de falha

Fornece o potencial instantâneo do evento **ocorrer**, dado que o indivíduo sobreviveu até o tempo  $t$ :

$$\lambda(t) = \frac{P(t \leq T < t + \Delta t | T \geq t)}{\Delta t}$$




Figura 2.1: Exemplo de uma função de sobrevivência

Note que estamos interessados em que o evento ocorra, ou seja, em termos de interpretação é o **oposto** da função de sobrevivência.

### 2.2.1 Consequências

- $\lambda(t) \geq 0$

Demonstração

É trivial pois por definição medidas de probabilidade  $\in [0, 1]$  e  $\Delta_t \geq 0$  portanto um produto de números positivos

- $\lambda(t) = \frac{f(t)}{S(t)} = -\frac{d}{dt} \left( \log(S(t)) \right)$



## 3 Programando

Nessa seção vamos aplicar o conceitos em três linguagens de programação, a saber: Python e R

### 3.1 Layout Básico

Os dados de sobrevivência possuem um layout estabelecido, que é dado a seguir:

Id	$T$	$s_i$	$X_i$	...	$X_p$
1	$t_1$	$s_1$	$x_{1i}$	...	$x_{1p}$
2	$t_2$	$s_2$	$x_{2i}$	...	$x_{2p}$
.	.	.	.	.	.
.	.	.	.	.	.
n	$t_n$	$s_n$	$x_{ni}$	...	$x_{np}$

R

```
tempo <- c(1, 2, 3, 3, 3, 5, 5, 16, 16, 16, 16, 16, 16, 16, 16, 1, 1, 1, 1, 4, 5, 7, 8, 10,
censura <- c(0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 0,
grupo <- c(rep(1, 15), rep(0, 14))
dados <- tempo |>
  cbind(censura) |>
  cbind(grupo)
dados |>
  head()
```

```
      tempo censura grupo
[1,]      1      0      1
[2,]      2      0      1
[3,]      3      1      1
[4,]      3      1      1
[5,]      3      0      1
[6,]      5      0      1
```



## 4 Análise Descritiva

Em Estatística é bastante usual fazer análise descritiva dos dados, como medidas resumo, gráficos e tabelas. Aqui também iremos elaborar análise descritivas, porém com foco nas medidas de sobrevivência e risco.

### **i** Nota

O símbolo  $\#$  aqui é utilizado para indicar a cardinalidade (quantidade de elementos) de um conjunto.

Por exemplo o conjunto  $A = \{a, b, d\}$ , possui cardinalidade 3, isso é  $\#A = 3$

### 4.1 Estimando a função de sobrevivência

Vamos nessa subseção estudar algumas maneiras de estimar a função de sobrevivência  $S(t)$

#### 4.1.1 Sem dados de censura

Uma maneira bastante intuitiva para estimarmos  $S(t)$  é tomarmos a quantidade de indivíduos que não falharam até o tempo  $t$  dividindo pelo total de indivíduos no estudo

$$\hat{S}(t) = \frac{\# \text{Observações que não falharam até } t}{\# \text{Observações}}$$

Na prática,  $S(t)$  será obtida por algum estimador, e portanto seu gráfico terá um formato de escada, como dado a seguir:

Pelo Figura 4.1 nota-se que a função mantém-se constante em alguns intervalos e tem um decaimento em alguns pontos específicos, a proxima seção formaliza tal idéia.




Figura 4.1: Exemplo de uma função de sobrevivência na prática

## 5 Estimador de Kaplan-Meier

O estimador de Kaplan-Meier também denominado limite-produto é uma adaptação da idéia ‘ingênua’ que utilizamos na seção anterior. Ele fornece uma maneira simples, mas eficiente de estimar a função de sobrevivência. De forma intuitiva, dividimos o tempo  $t$  em uma série de intervalos de acordo com os eventos observados ou dados censurados, após isso calculamos uma sequência de produto de probabilidade condicionais

### 5.1 Outra maneira de layout para os dados

t				
ordenados	int	# de falhas	$n_j$	$m_j$
0	$[0, t_1)$	0	$k$	$x_{1p}$
$t_1$	$[t_1, t_2)$	$d_2$	$k - d_1$	$x_{2p}$
$t_2$	$[t_2, t_3)$	.	.	.
.	.	.	.	.
.	.	.	.	.
k	$[t_k, t_{k+\epsilon})$	$d_k$	$k - \sum_i d_i$	$x_{np}$

- **int:** São os intervalos
- **# de falhas:** É o número de falhas naquele intervalo
- $n_j$  : É a quantidade de observações que ainda não falharam naquele intervalo (as vezes chamado de indivíduos sob risco)

Assim fica fácil ver que no tempo 0 temos 0 falhas, porque como vamos ver a seguir a construção dos intervalos começa a partir do primeiro tempo que acontece um evento, e como temos 0 falhas temos portanto todos os indivíduos sem o evento de interesse

### 5.2 Formalizando

Sabemos que  $S(t) = P(T > t)$ , vamos supor que já construímos a tabela e possuímos o tempo 3 e 1, assim queremos calcular, por exemplo:

$$S(3) = P(T > 3)$$

Podemos fazer a seguinte manipulação:

$$S(3) = P(T > 3) = P(T > 1, T > 3) = P(T > 1)P(T > 3|T > 1)$$

**i** Nota

Lembre que  $f(X|Y) = \frac{f(X, Y)}{f(Y)}$

E que se A é subconjunto de B, então  $A \cap B = A$  (relacione aos intervalos  $(1, \infty)$  e  $(3, \infty)$ )

Vamos utilizar o seguinte exemplo para ilustrar a idéia anterior:

t ordenados	int	# de falhas ( $d_j$ )	$n_j$	$\hat{S}(\cdot)$
0	[0, 1)	0	14	1
1	[1, 5)	3	14	0.78
5	[5, 7)	1	9	.
7	[7, 8)	1	8	.
8	[8, 10)	1	7	.
10	[10, 16)	1	6	$x_{np}$

Para calcular  $\hat{S}(1)$ , fazemos então:

$$P(T > 1) = P(T > 0, T > 1) = P(T > 0)P(T > 1|T > 0)$$

Sabemos que  $P(T > 0) = 1$  como comentado anteriormente. Temos 3 acontecimentos do evento de interesse no tempo  $t = 1$  e 14 observações restantes, assim a probabilidade de ‘falhar’ nesse intervalo é  $\frac{3}{14}$ , portanto a probabilidade de sobreviver é  $1 - \frac{3}{14}$ , substituindo as informações tem-se portanto que  $\hat{S}(1) = 0.786$

Para  $\hat{S}(5)$ , fazemos a mesma decomposição de probabilidade e chegamos em:

$$\hat{S}(5) = P(T > 1)P(T > 5|T > 1)$$

Como calculado anteriormente  $P(T > 1) = 1 - \frac{3}{14}$  e  $P(T > 5|T > 1) = 1 - \frac{1}{9}$ .

Fica claro então a relação de recursão, pois para o cálculo da estimativa utiliza-se todas as probabilidades calculadas anteriormente, generalizando temos:

$$S(t_j) = (1 - q_1)(1 - q_2) \dots (1 - q_j) = \prod_{j:t_j < t} \left(1 - \frac{d_j}{n_j}\right) = \prod_{j:t_j < t} \left(\frac{n_j - d_j}{n_j}\right)$$

Onde  $q_j$  é a probabilidade de uma observação ter o evento de interesse no intervalo  $[t_{j-1}, t_j)$  sabendo-se que não teve em  $t_{j-1}$ , formalizando tem-se:

$$q_j = P(T \in [t_{j-1}, t_j) | T > t_{j-1})$$

Assim o estimador reduz-se a estimar os  $q_j$ , reescrevendo usando alguns termos já citados temos:

$$\hat{q}_j = \frac{\# \text{ de falhas em } t_j}{\# \text{ Observações sobre risco}}$$

#### ! Importante

Os métodos construídos anteriormente são ditos **não-paramétricos**, pois para a derivação dos estimadores não se faz pressuposto de distribuição para a variável aleatória  $T$

## 5.3 Propriedades do estimador

Como temos um estimador pontual, podemos também construir intervalos de confiança para a estimativas.

### 5.3.1 Variância do Estimador

Ora ora, para calcular a variância do estimador precisamos saber a distribuição do estimador, então aqui vamos nos conter com o estimador da variância do estimador, que é dado por:

$$\widehat{\text{Var}}(\hat{S}(t)) = [\hat{S}(t)]^2 \sum_{j: t_j < t} \frac{d_j}{n_j(n_j - d_j)}$$

## 5.4 Códigos

Python

```
import pandas as pd
import numpy as np
from lifelines import KaplanMeierFitter
#%%
```

```

tempo = [1, 1, 1, 1, 4, 5, 7, 8, 10, 10, 12, 16, 16, 16]
falha = [1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 0, 0, 0, 0]

dados = pd.DataFrame({'tempo':tempo,'censura':falha})

# %%
KaplanMeierFitter().fit(dados['tempo'],dados['censura']).survival_function_

```

	KM_estimate
timeline	
0.0	1.000000
1.0	0.785714
4.0	0.785714
5.0	0.698413
7.0	0.611111
8.0	0.523810
10.0	0.436508
12.0	0.436508
16.0	0.436508



## 6 Summary

In summary, this book has no content whatsoever.

## Referências

Colosimo, Suely Ruiz, Enrico Antonio e Giolo. 2006. *Análise de sobrevivência aplicada*. Editora Blucher.